Wykrywanie spamu w wiadomościach SMS

Milestone 1: dane, EDA, podział i hipotezy przetwarzania

[Imię Nazwisko] [Imię Nazwisko] [Imię Nazwisko]

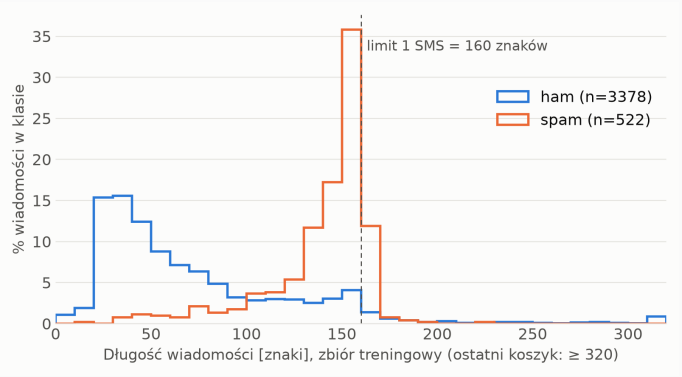
29.10.2026

Reprezentacja danych · projekt · temat 4: SMS Spam Collection

Dane: 5574 SMS-y, 13,4% spamu

- SMS Spam Collection v.1 UCI #228, CC BY 4.0
- **ham** 4827 **spam** 747
- braki i puste: **0**
- emoji: **0** (rok 2011)
- 35 SMS-ów z błędnym cp1252
- SHA-256 pliku zapisany
- `id` = nr linii pliku

Metryka główna:
F1 dla klasy spam



Spam celuje w limit jednego SMS-a: mediana **149** znaków (ham: 53), 74,7% spamu ma 120–160 znaków.

Duplikaty i podział bez przecieku

- **403** dokładne duplikaty (7,2%); spam powtarza się 2× częściej (12,6% vs 6,4%)
- **0** tekstów z konfliktem etykiet
- Bliskie duplikaty: cosinus TF-IDF n-gramów znakowych 3–5 $\geq 0{,}7$, czyli 4897 grup (największa: 40). Najczęściej ten sam szablon spamu z innym numerem.
- Decyzja: zostawiamy wszystkie rekordy, a każda grupa trafia w całości do jednej części.

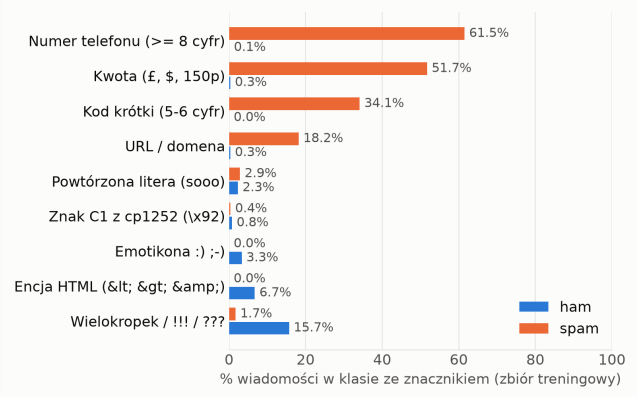
część	ham	spam	razem	% spam
train	3378	522	3900	13,4
val	725	112	837	13,4
test	724	113	837	13,5

70/15/15, StratifiedGroupKFold, seed 42

`data/splits/split_seed42.csv`

0 rekordów val/test z cos $\geq 0{,}7$ do treningu

Co odróżnia spam od hamu (zbiór treningowy)



Numery są silne, ale nowe

W 85,5% spamów z walidacji z numerem telefonu żaden numer nie wystąpił w treningu.

Artefakt korpusu

`gt` i `1t` to dwa najsilniejsze tokeny hamu w B1: ślad placeholdera `<#>` z korpusu NUS.

Interpunkcja to ham

Wielokropki i emotikony są typowe dla hamu, ale tokenizer B1 je pomija.

Trzy hipotezy: ten sam model B1, zmieniamy tylko tekst

P1: maskowanie numerów i kwot

`<PHONE>` `<SHORTCODE>` `<MONEY>`

Dlaczego: numer telefonu w 61,5% spamu, ale 71% długich liczb z walidacji jest spoza słownika.

Oczekujemy: wyższego recall spamu i F1.

Ryzyko: hamy z kwotami (`$700`).

P2: URL, maskowanie vs usuwanie

`<URL>` albo usunięcie

Dlaczego: URL w 18,2% spamu, ale tokenizer już rozbija domeny (`uk`: 50 spam / 1 ham).

Oczekujemy: maskowanie bez większej zmiany, usunięcie obniży recall.

P3: normalizacja powtórzeń

`sooo`→`soo`, `!!!!`→`!!`

Dlaczego: powtórzenia tylko w 2–3% wiadomości obu klas.

Oczekujemy: braku istotnej zmiany na czystym teście; ewentualny zysk w teście odporności na literówki.

Najpierw zmiany pojedyncze, potem połączenie najlepszych. Opcjonalnie P4: dekodowanie encji HTML (usuwa skrót `lt/gt`).

Problemy i plan na Milestone 2

Problemy i ryzyka

- Mały test: 113 spamów, więc 1 SMS $\approx$ 0,9 p.p. recall. Potrzebny sparowany bootstrap.
- 65 ze 113 spamów testu jest w grupach duplikatów. Raportujemy też test po deduplikacji (781 unikalnych).
- 41 spamów testu przypomina kampanie z treningu (cos 0,5–0,7). Pokażemy wynik na podzbiorze $< 0{,}5$.
- Do potwierdzenia: grupowanie zamiast deduplikacji, próg 0,7.

Plan M2

- B0: klasa większościowa (ham), F1 spamu $= 0$
- B1: TF-IDF na surowym tekście (`lowercase`, domyślny `token_pattern`) + regresja logistyczna; `C` i próg decyzji tylko na walidacji
- P1–P3 na zamrożonym B1, potem połączenie najlepszych
- Osobny eksperyment: n-gramy słowne vs znakowe