Wykrywanie spamu w wiadomościach SMS

Milestone 2

Jerzy Czarnecki Mateusz Małachowski Sebastian Rydz Wojciech Wójcik

12.11.2026

B0, reguła B0r i B1: punkty odniesienia

- Zamrożony podział z M1: te same 837 rekordy testowe dla wszystkich wariantów
- **B0**: zawsze **ham**, F1 spamu $= 0$
- **B0r**: spam, gdy jest ≥ 1 znacznik z EDA (telefon, kwota, kod krótki, URL); próg k z walidacji
- **B1**: surowy tekst $\rightarrow$ TF-IDF $\rightarrow$ regresja logistyczna
  - małe litery, domyślny `token_pattern`, unigramy, L2
  - TF-IDF tylko na treningu; `C` $= 300$ i próg z walidacji

test	B0	B0r	B1
F1 spam	0,000	0,936	**0,940**
precision spam	0,000	0,963	0,990
recall spam	0,000	0,912	0,894
PR-AUC	0,135	0,915	0,980
FP / FN	0 / 113	4 / 10	1 / 12
F1 spam (val)	0,000	0,905	0,922

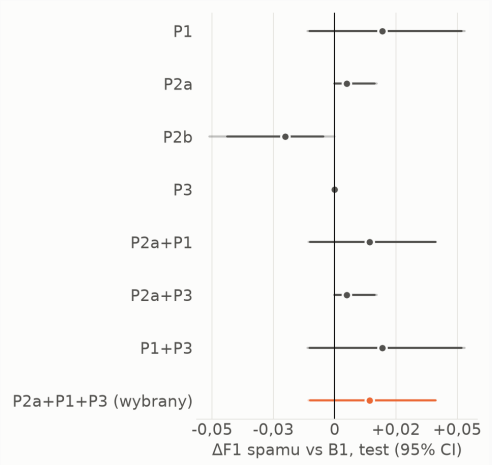
B1 − B0r na teście: +0,3 p.p., CI [−3,6; +4,2]. Reguła łapie większość spamu, B1 daje mniej fałszywych alarmów i lepszy ranking.

P1–P3: ten sam wektoryzator, to samo `C`, inny tekst

		walidacja		test	
wariant	zmiana tekstu	F1 spam	PR-AUC	F1 spam	FP / FN
B1	brak	0,922	0,962	0,940	1 / 12
P1	`_phone_ _shortcode_ _money_`	**0,959**	0,974	**0,959**	1 / 8
P2a	URL → `_url_`	0,926	0,963	0,944	1 / 11
P2b	URL usunięty	0,906	0,957	0,919	1 / 16
P3	`sooo`→`soo`, `!!!`→`!!`	0,922	0,963	0,940	1 / 12
P2a+P1+P3 (wybrany na walidacji)		0,968	0,975	0,954	0 / 10

- Próg decyzji osobno dla każdego wariantu, tylko na walidacji. Wariant końcowy wybrany na walidacji, test tylko raportujemy.
- Łączymy warianty, które na walidacji nie pogorszyły F1 ani PR-AUC. P3 w połączeniu nic nie zmienia (remis z P2a+P1).

Czy poprawa jest pewna? Bootstrap sparowany na teście



ciemna: losowanie rekordów; jasna: losowanie grup

- **P1**: $+1{,}9$ p.p., CI $[-1{,}0;\ +5{,}2]$. Kierunek zgodny z H1, ale 113 spamów to za mało na pewność.
- **P2b**: $-2{,}0$ p.p., CI $[-4{,}4;\ -0{,}5]$. Usuwanie URL szkodzi, bo model korzysta z domen (H2).
- **P3**: identyczne predykcje jak B1 na czystym tekście (H3).
- Wybrany wariant: $+1{,}4$ p.p., CI $[-1{,}0;\ +4{,}1]$.
- Losowanie całych grup duplikatów daje podobne lub nieco szersze przedziały.

Trudniejsze warunki: podzbiory testu i literówki

F1 spamu na podzbiorach testu

podzbiór	spam	B1	wybrany
cały test	113	0,940	0,954
bez duplikatów	102	0,938	0,954
podobieństwo $< 0{,}5$	72	0,902	0,925

Bez kampanii podobnych do treningu oba modele tracą 3–4 p.p.

Literówki w X% słów testu (3 ziarna)

	0%	10%	20%
B1	0,940	0,936	0,917
P3	0,940	0,936	0,922
wybrany	0,954	0,949	0,947

Odchylenie między ziarnami $\approx 0{,}01$, więc zysk P3 mieści się w szumie. Maski numerów nie zależą od pisowni.

Problemy i plan na Milestone 3

Problemy

- Różnice między wariantami to kilka SMS-ów: 1 spam $\approx$ 0,9 p.p. recall.
- Prosta reguła jest blisko B1, więc znaczniki niosą większość sygnału; P1 przenosi je do modelu.
- Na teście sam P1 wypada lepiej niż wybrane połączenie. Nie zmieniamy wyboru, bo byłby to dobór na teście.
- Niewykryte spamy to głównie wiadomości bez numeru i URL (randki, reklamy) albo z numerem w dziwnej formie (`146tf150p`).

Plan M3

- Stabilność efektu P1: powtórzona grupowa walidacja krzyżowa na train+val
- P4: dekodowanie encji HTML (`<#>`) jako analiza wrażliwości
- Osobny eksperyment: n-gramy słowne vs znakowe
- Model M: zamrożone embeddingi zdań + regresja logistyczna, strojenie na walidacji