# Wykrywanie spamu w wiadomościach SMS

Milestone 2

Jerzy Czarnecki  Mateusz Małachowski  Sebastian Rydz  Wojciech Wójcik

12.11.2026

# B0 i B1: punkt odniesienia

- Zamrożony podział z M1: te same 837 rekordy testowe dla wszystkich wariantów
- **B0**: zawsze **ham**, F1 spamu = 0
- **B1**: surowy tekst → TF-IDF → regresja logistyczna
  - małe litery, domyślny `token_pattern`, unigramy, L2
  - TF-IDF dopasowany tylko do treningu
  - `C` = 300 wybrane na walidacji (PR-AUC)
  - próg decyzji: maks. F1 na walidacji
- Wszystkie ustawienia w `configs/experiments.toml`

| test | B0 | B1 |
|---|---|---|
| F1 spam | 0,000 | **0,940** |
| precision spam | 0,000 | 0,990 |
| recall spam | 0,000 | 0,894 |
| macro-F1 | 0,464 | 0,965 |
| PR-AUC | 0,135 | 0,980 |
| FP / FN | 0 / 113 | 1 / 12 |

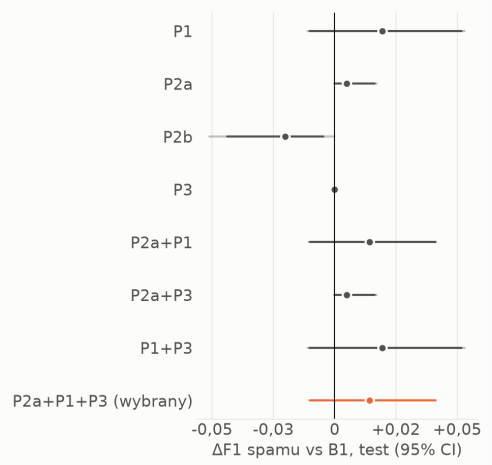
Trening $<$ 0,05 s na CPU (Apple M5 Pro).

# P1–P3: ten sam wektoryzator, to samo `C`, inny tekst

| | | walidacja | | test | |
|---|---|---|---|---|---|
| wariant | zmiana tekstu | F1 spam | PR-AUC | F1 spam | FP / FN |
| B1 | brak | 0,922 | 0,962 | 0,940 | 1 / 12 |
| P1 | `_phone_ _shortcode_ _money_` | **0,959** | 0,974 | **0,959** | 1 / 8 |
| P2a | URL → `_url_` | 0,926 | 0,963 | 0,944 | 1 / 11 |
| P2b | URL usunięty | 0,906 | 0,957 | 0,919 | 1 / 16 |
| P3 | `sooo`→`soo`, `!!!`→`!!` | 0,922 | 0,963 | 0,940 | 1 / 12 |
| **P2a+P1+P3** (wybrany na walidacji) | | 0,968 | 0,975 | 0,954 | 0 / 10 |

- Próg decyzji osobno dla każdego wariantu, tylko na walidacji. Wariant końcowy wybrany na walidacji, test tylko raportujemy.
- Łączymy warianty, które na walidacji nie pogorszyły F1 ani PR-AUC. P3 w połączeniu nic nie zmienia (remis z P2a+P1).

# Czy poprawa jest pewna? Bootstrap sparowany na teście




ciemna: losowanie rekordów; jasna: losowanie grup

- **P1**: $+1{,}9$ p.p., CI $[-1{,}0;\ +5{,}2]$. Kierunek zgodny z H1, ale 113 spamów to za mało na pewność.
- **P2b**: $-2{,}0$ p.p., CI $[-4{,}4;\ -0{,}5]$. Usuwanie URL szkodzi, bo model korzysta z domen (H2).
- **P3**: identyczne predykcje jak B1 na czystym tekście (H3).
- Wybrany wariant: $+1{,}4$ p.p., CI $[-1{,}0;\ +4{,}1]$.
- Losowanie całych grup duplikatów daje podobne lub nieco szersze przedziały.

# Trudniejsze warunki: podzbiory testu i literówki

**F1 spamu na podzbiorach testu**

| podzbiór | spam | B1 | wybrany |
|---|---|---|---|
| cały test | 113 | 0,940 | 0,954 |
| bez duplikatów | 102 | 0,938 | 0,954 |
| podobieństwo $< 0{,}5$ | 72 | 0,902 | 0,925 |

Bez kampanii podobnych do treningu oba modele tracą 3–4 p.p.

**Literówki w X% słów testu** (3 ziarna)

| | 0% | 10% | 20% |
|---|---|---|---|
| B1 | 0,940 | 0,936 | 0,917 |
| P3 | 0,940 | 0,936 | 0,922 |
| wybrany | 0,954 | 0,949 | 0,947 |

Odchylenie między ziarnami $\approx 0{,}01$, więc zysk P3 mieści się w szumie. Maski numerów nie zależą od pisowni.

# Problemy i plan na Milestone 3

## Problemy

- Różnice między wariantami to kilka SMS-ów: 1 spam $\approx$ 0,9 p.p. recall.
- Na teście sam P1 wypada lepiej niż wybrane połączenie. Nie zmieniamy wyboru, bo byłby to dobór na teście.
- Niewykryte spamy to głównie wiadomości bez numeru i URL (randki, reklamy) albo z numerem w dziwnej formie (`146tf150p`).

## Plan M3

- Stabilność efektu P1: powtórzona grupowa walidacja krzyżowa na train+val
- P4: dekodowanie encji HTML (`<#>`) jako analiza wrażliwości
- Osobny eksperyment: n-gramy słowne vs znakowe
- Model M: zamrożone embeddingi zdań + regresja logistyczna, strojenie na walidacji